LAPORAN TUGAS BESAR 1

JARINGAN SYARAF TIRUAN



Anggota Kelompok:

Mikhael Lev Hasiholan N.	71230991
Christjevicto Ajimas Kirana	71230998
Moses Satriyo Gentur P.	71231016
Vanessa Rupina S.	71231024
Richard Vanuella	71241159

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNOLOGI INFORMASI

UNIVERSITAS KRISTEN DUTA WACANA

YOGYAKARTA

2026

1. Masalah dan Tujuan

1.1. Perumusan Kasus

Dataset berisi pengukuran karakteristik inti sel pada sampel payudara yang telah memiliki label diagnosis. Masalah dirumuskan sebagai supervised binary classification: model menerima fitur numerik dan mempelajari keputusan antara sampel jinak (B) dan ganas (M). Kedua kelas memang sudah tersedia dari sumber. Label tidak dibuat dari threshold fitur atau hasil clustering.

Pengukuran citra aspirasi jarum halus atau fine needle aspirate (FNA) menjadi konteks sumber data [1-2]. Eksperimen ini bekerja pada angka hasil ekstraksi, bukan memproses citra mikroskop dari awal. Hasil tidak ditafsirkan sebagai prediksi risiko pada populasi umum.

1.2. Tujuan Eksperimen

Tujuan pertama ialah mengimplementasikan neuron linear, Perceptron, dan ADALINE secara mandiri dengan NumPy mengikuti persamaan panduan. Tujuan berikutnya ialah membandingkan mekanisme error, pengaruh learning rate, perkembangan epoch, serta pengaruh standardisasi dengan pengendalian split dan kondisi awal.

Evaluasi mencakup akurasi latih/uji, jumlah kesalahan latih, confusion matrix, precision, recall dan F1 untuk kelas M. Riwayat pembaruan Perceptron dan loss ADALINE membantu menjelaskan proses pembelajaran. Akurasi sempurna tidak menjadi syarat keberhasilan studi.

1.3. Hubungan dengan Tugas 1

Presentasi Tugas 1 membahas segmentasi pelanggan Mall Customers, tanpa target segmen, dengan rencana SOM/Kohonen. Panduan TB1 menuntut Perceptron dan ADALINE untuk dua kelas. Karena itu, kasus diubah menjadi klasifikasi diagnosis pada dataset berlabel. Studi ini tidak mengklaim tetap memakai observasi pelanggan atau melanjutkan eksperimen clustering yang sama.

Penggantian dataset telah dikonsultasikan sesuai bagian C.1 berdasarkan konfirmasi kelompok. Sumber Kaggle dipilih dan file data.csv diunggah langsung, sehingga masalah akses sumber sebelumnya tidak menjadi ketergantungan eksperimen. Bukti persetujuan tambahan, jika diminta dosen, tetap menjadi tanggung jawab kelompok.

1.4. Keputusan Ruang Lingkup

Empat fitur yang telah direkomendasikan sebelum evaluasi dipakai untuk menjaga keterbacaan perhitungan manual: radius_mean, texture_mean, smoothness_mean, dan concavity_mean. Pemilihan ini mencakup ukuran, tekstur dan bentuk, serta tidak sekaligus menggunakan radius, perimeter dan area yang sama-sama terkait ukuran. Tidak dilakukan pencarian subset berdasarkan hasil data uji.

Semua 569 baris dipertahankan. Model tetap berdimensi empat. Visualisasi batas keputusan memperlihatkan irisan hiperbidang dengan dua fitur lain ditahan pada rerata train, bukan hasil pelatihan model dua fitur. Keputusan desain ini dicatat sebelum pelaporan data uji.

2. Dataset dan Label

2.1. Sumber dan Izin

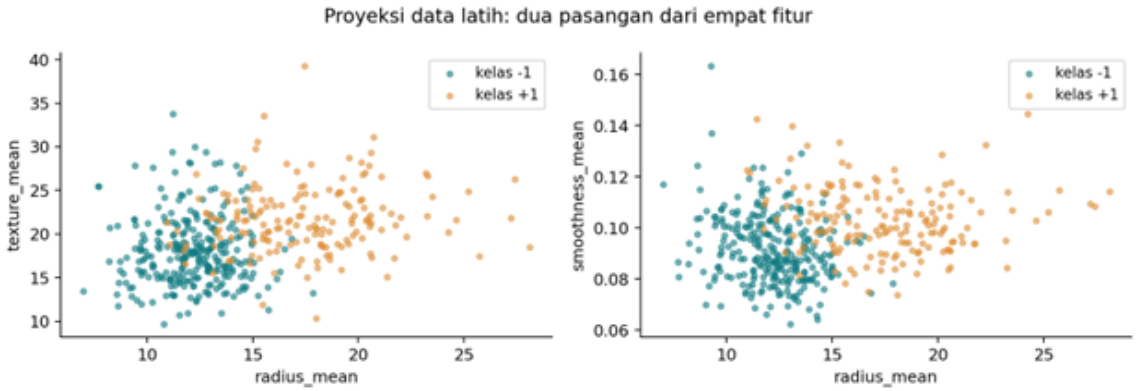
Data berasal dari file data.csv yang diunggah kelompok dari halaman Kaggle UCI Machine Learning [1]. Sumber asli adalah Breast Cancer Wisconsin (Diagnostic), DOI 10.24432/C5DW2B [2]. Metadata Kaggle menyebut CC BY-NC-SA 4.0, sedangkan UCI menyebut CC BY 4.0. Untuk salinan Kaggle dan CSV turunannya, paket mempertahankan atribusi serta ketentuan nonkomersial dan berbagi-serupa Kaggle. Kedua lisensi dibedakan dalam DATA_LICENSE.md.

Kolom dataset.csv	Makna dan peran
radius_mean	Rerata jarak dari pusat inti sel ke titik pada perimeter. Mewakili ukuran.
texture_mean	Rerata karakteristik tekstur, dihitung dari simpangan baku intensitas keabuan.
smoothness_mean	Rerata variasi lokal panjang radius. Mewakili kehalusan batas inti sel.
concavity_mean	Rerata tingkat cekungan bagian kontur isi sel.
diagnosis	Target asli B atau M, tidak menjadi fitur.
label	Target bipolar: B = 1, M =+ 1. Kelas positif ialah M.

2.2. Audit dan Distribusi

File mentah memiliki 569 baris dan 33 kolom: 30 pengukuran, id, diagnosis, dan Unnamed: 32. Kolom terakhir berisi 569 nilai kosong dan dibuang dari data eksperimen. Tidak ada missing value pada fitur/target atau duplikasi baris. Semua ID unik dan 30 fitur tidak mempunyai baris duplikat. ID adalah pengenal rekaman publik dan tidak dimasukkan ke X. Tidak diperlukan imputasi, deduplikasi atau penghapusan outlier.

Subset	Jumlah	B (-1)	M (+1)
Keseluruhan	569	3357	212
Train	455	285	170
Test	114	72	42



Gambar 1. Proyeksi data latih pada dua pasangan dari empat fitur. Pola tumpang tindih pada proyeksi tidak menentukan separabilitas ruang empat dimensi.

3. Rujukan dan Model Neuron

3.1. Artikel Ilmiah dan Kode Pendukung

Sumber	Kontribusi dan adaptasi
Widrow & Hoff (1960) [3]	Artikel fundamental asli tentang pembelajaran adaptif dengan error kuadrat. Pembaruan batch rerata mengikuti panduan TB1, bukan klaim bahwa seluruh kode identik dengan perangkat asli.
Raschka (2015) [4]	Struktur loop neuron dan aturan Perceptron/ADALINE. Kode disusun ulang dengan bias terpisah, w=b=0, urutan tetap, dan pencatatan tiap epoch.
mlxtend [5]	Linear output vs threshold serta gradient descent. Estimator siap pakai tidak dipanggil. Gradient dibagi n dan J dicatat sesudah update sesuai rubrik.
scikit-learn [6]	Hanya split, scaler dan metrik. Parameter scaler dipelajari dari train. Contoh standardisasi sebelum split pada rujukan tidak diikuti.

3.2. Neuron dan Perceptron

$z = w^T x + b$; $\hat{y} = +1$ jika $z \geq 0$, selain itu -1
$\Delta = \eta(y - \hat{y})$; w baru = $w + \Delta x$; b baru = $b + \Delta$

Empat bobot memberi kontribusi linear fitur, bias menggeser hiperbidang, dan z bukan probabilitas. Perceptron memakai error label. Jika prediksi benar, $\Delta=0$. Jika salah, $\Delta=\pm 2\eta$. Update berlangsung segera per sampel. Jumlah update dalam epoch berbeda dari kesalahan seluruh train sesudah epoch karena parameter terus berubah saat loop berjalan.

3.3. ADALINE dan Delta Rule

$e = y - (Xw + b)$; $J = \Sigma e_i^2/(2n)$; $MSE = 2J$
w baru = $w + \eta X^T e/n$; b baru = $b + \eta$ mean(e)

Error berasal dari output linear. Semua komponen gradient memakai bobot lama yang sama. Ambang dipakai hanya untuk prediksi/metrik. J dicatat sesudah pembaruan batch. Jika parameter atau J menjadi inf/NaN, pelatihan berhenti dan state valid terakhir dipertahankan. Dua sampel Perceptron serta dua batch aktual ADALINE pada η=0,01 ditelusuri di Lampiran A-B.

4. Penyiapan dan Rancangan Eksperimen

4.1. Pengendalian Data

Split 80:20 menggunakan train_testsplit(test_size=0.2, random_state=42, stratify=y), sehingga diperoleh 455 train dan 114 test. Split, inisialisasi w=(0,0,0,0), b=0 dan urutan sampel dipertahankan untuk seluruh konfigurasi. Semua epoch menggunakan urutan hasil split yang sama, tanpa pengacakan ulang.

x standar = (x - μ train) / σ train, dengan ddof=0

Fitur	μ train	σ train
radius_mean	14.166076923	3.575145843
texture_mean	19.417692308	4.285935362
smoothness_mean	0.095992945	0.014293957
concavity_mean	0.089184283	0.081608175

4.2. Delapan Konfigurasi Apriori

ID	Model	η	Skala	Epoch
P-S-0001	Perceptron	0.001	Standar	50
P-S-001	Perceptron	0.01	Standar	50
P-S-01	Perceptron	0.1	Standar	50
A-S-0001	ADALINE	0.001	Standar	50
A-S-001	ADALINE	0.01	Standar	50
A-S-01	ADALINE	0.1	Standar	50
P-R-001	Perceptron	0.01	Asli	50
A-R-001	ADALINE	0.01	Asli	50

Enam pelatihan utama mengikuti learning rate 0,001; 0,01; 0,1. Dua kontrol tanpa standardisasi memakai η=0,01. Anggaran 50 epoch ditetapkan tanpa early stopping pada nol kesalahan. Semua konfigurasi selesai 50 epoch. Loss raw yang besar tetapi finite tidak dihentikan atau diganti dengan eksperimen yang tampak lebih baik.

4.3. Penggunaan Data Uji

Konfigurasi dan empat fitur ditentukan sebelum evaluasi test. Seluruh model dilatih terlebih dahulu, lalu hasil uji akhir tiap konfigurasi dilaporkan. Tidak dilakukan seleksi model/parameter. Fokus η=0,01 dipilih sebelum evaluasi. Checkpoint 10/30/50 diambil dari riwayat train yang sama. Seleksi lanjutan harus memakai validasi di dalam train.

5. Hasil Akhir dan Parameter

5.1. Tabel Seluruh Konfigurasi

ID	Model	η	Std	E	Acc. train	Acc. test	Salah train	Update/Loss akhir
P-S-0001	Perceptron	0.001	Ya	50	92.09%	89.47%	36	U=43
P-S-001	Perceptron	0.01	Ya	50	92.09%	89.47%	36	U=43
P-S-01	Perceptron	0.1	Ya	50	92.09%	89.47%	36	U=43
A-S-0001	ADALINE	0.001	Ya	50	93.41%	93.86%	30	J=0.441136
A-S-001	ADALINE	0.01	Ya	50	93.41%	92.11%	30	J=0.218392
A-S-01	ADALINE	0.1	Ya	50	92.53%	90.35%	34	J=0.164894
P-R-001	Perceptron	0.01	Tidak	50	40.88%	39.47%	269	U=116
A-R-001	ADALINE	0.01	Tidak	50	37.36%	36.84%	285	J=6.659e+67

E= Epoch selesai; **U** = Update salah klasifikasi pada epoch terakhir. **J** dan **MSE** = 2J hanya berlaku untuk ADALINE. J dihitung sesudah update, dan semua pelatihan masih finite. Parameter dan loss raw yang sangat besar menunjukkan divergensi, bukan konvergensi.

5.2. Bobot dan Bias Akhir

ID	w radius	w texture	w smooth	w concavity	bias
P-S-0001	0.009747	0.005578	0.006261	0.003761	-0.006000
P-S-001	0.097474	0.055778	0.062612	0.037611	-0.060000
P-S-01	0.974742	0.557781	0.626122	0.376109	-0.600000
A-S-0001	0.033621	0.019037	0.017779	0.031347	-0.012333
A-S-001	0.229680	0.125963	0.111784	0.200048	-0.099834

A-S-01	0.450228	0.190320	0.168005	0.222465	-0.251445
P-R-001	1.171140	0.401200	-0.806771	5.593895	-17.380000
A-R-001	2.767e+32	3.809e+32	1.818e+30	1.841e+30	1.889e+31

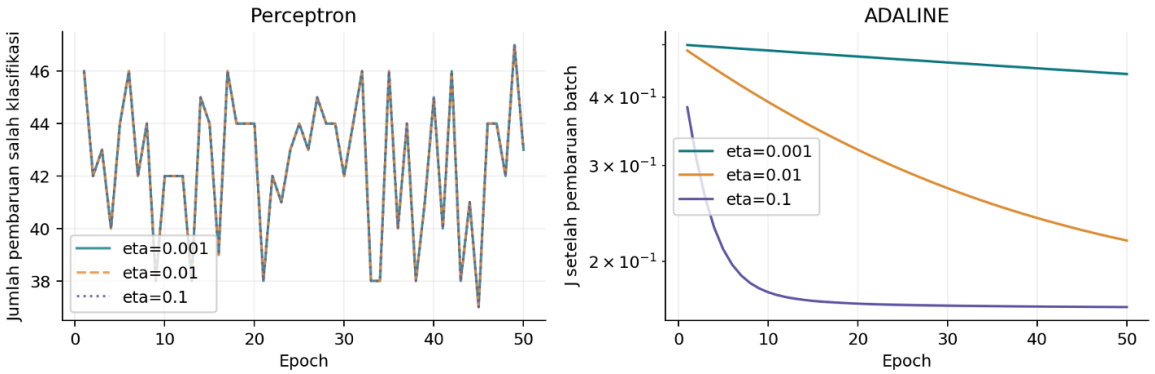
Urutan bobot sama dengan FEATURES. Baris S berada di koordinat standar, R pada skala asli. Angka dibulatkan untuk tampilan, pada CSV menyimpan *precision* lebih tinggi. Besarnya bobot antar-skala tidak dapat dibandingkan langsung sebagai ukuran kepentingan fitur.

5.3. Hasil Klasifikasi dan Objektif

Kesalahan latih Perceptron standar pada epoch 10/30/50 adalah 34/42/36. Kesalahan tidak turun monoton. Pada ADALINE standar, eta 0.1 menghasilkan J akhir 0.164894, lebih rendah daripada eta 0.01 (0.218392), tetapi akurasi uji 90.35% justru lebih rendah daripada 92.11%. Objektif kuadrat dan kesalahan kelas mengukur hal berbeda. Epoch 50 adalah anggaran tetap, bukan epoch terbaik hasil seleksi data uji.

ADALINE standar η=0,001 memberi 107 prediksi uji benar dari 114, η=0,01 memberi 105, dan η=0,1 memberi 103. Hasil ini merupakan pelaporan konfigurasi tetap, bukan pemilihan model terbaik untuk aplikasi. Baseline selalu memprediksi B memberi akurasi 72/114=63,16% pada test. Kontrol raw menunjukkan bahwa tinggi atau rendahnya akurasi perlu dibaca bersama dinamika loss.

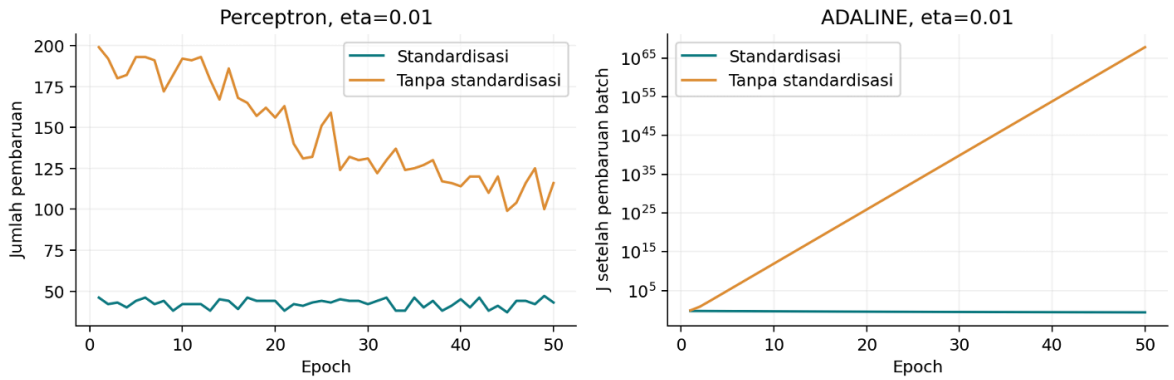
6. Kurva dan Perkembangan Epoch



Gambar 2. Kurva Perceptron memakai update selama epoch, ADALINE memakai J sesudah batch pada sumbu log. Tiga kurva Perceptron bertumpuk karena penskalaan positif bobot.

ID	E10 U/J	E10 Salah	E30 U/J	E30 Salah	E50	E50
P-S-0001	42	34	42	42	43	36
P-S-001	42	34	42	42	43	36
P-S-01	42	34	42	42	43	36
A-S-0001	0.4873	31	0.4633	30	0.4411	30
A-S-001	0.3923	30	0.2725	30	0.2184	30
A-S-01	0.1756	31	0.1659	32	0.1649	34
P-R-001	192	282	131	281	116	269
A-R-001	8.180e+11	285	7.380e+39	285	6.659e+67	285

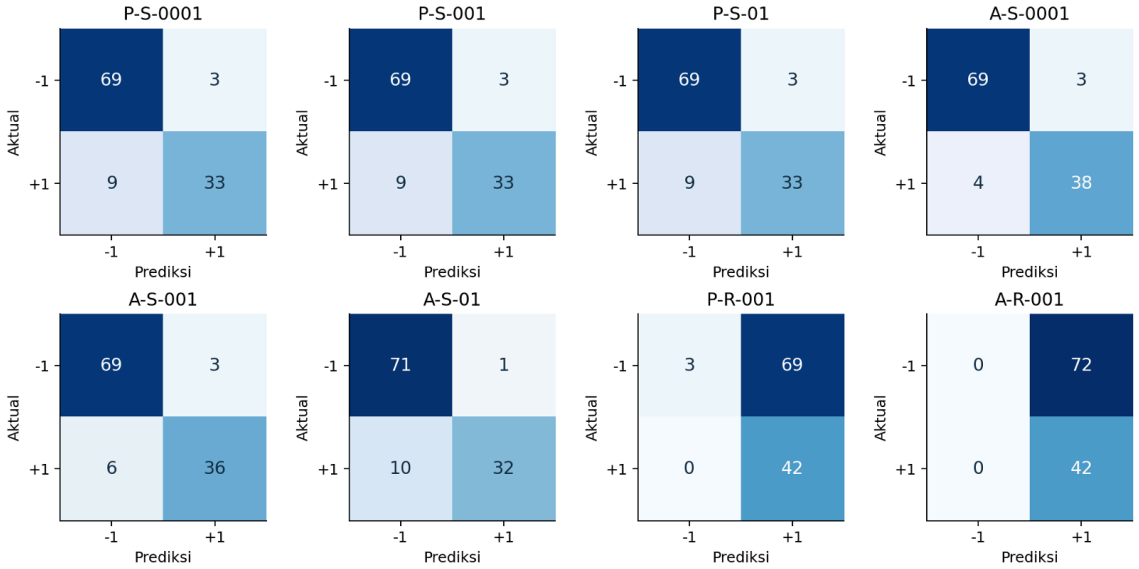
U = jumlah update Perceptron. **Salah** = kesalahan seluruh train memakai bobot akhir epoch. Checkpoint berasal dari satu riwayat, bukan pelatihan terpisah.



Gambar 3. Kontrol skala pada η=0,01. Sumbu J logaritmik mempertahankan keterbacaan loss raw yang membesar hingga $6{,}659\times10^{67}$. Semua 50 epoch tetap ditampilkan.

Untuk J kuadratik, H=A.T@A/n dengan A=[X,1]. Rentang stabil gradient descent adalah 0<eta<2/lambda_max(H). Dari train diperoleh batas 0.954260 pada fitur standar dan 0.003334 pada fitur raw. Eta 0.01 melampaui batas raw. J masih finite hingga epoch 50, sehingga pelatihan tidak dihentikan dan epoch non-finite dicatat sebagai tidak terjadi. Tidak ada perubahan eta setelah melihat hasil uji.

7. Confusion Matrix dan Kelas Positif



Gambar 4. Delapan matriks test. Baris=aktual dan kolom=prediksi, keduanya [-1,+1]. Susunan [[TN,FP],[FN,TP]]. B=-1, M=+1. Angka di setiap matriks berjumlah 114.

ID	Precision M	Recall M	F1 M	Balanced acc.
P-S-0001	0.9167	0.7857	0.8462	0.8720
P-S-001	0.9167	0.7857	0.8462	0.8720
P-S-01	0.9167	0.7857	0.8462	0.8720
A-S-0001	0.9268	0.9048	0.9157	0.9315
A-S-001	0.9231	0.8571	0.8889	0.9077
A-S-01	0.9697	0.7619	0.8533	0.8740
P-R-001	0.3784	1.0000	0.5490	0.520
A-R-001	0.3684	1.0000	0.5385	0.5000

Kelas M (+1) berjumlah 42 dari 114 data uji. Perceptron standar eta=0.01 memiliki FN=9, FP=3, recall=0.7857. ADALINE standar eta=0.01 memiliki FN=6, FP=3, recall=0.8571. FN berarti sampel ganas diprediksi jinak, sehingga akurasi saja tidak cukup. Ini hanya evaluasi benchmark, bukan rekomendasi diagnosis klinis.

Pada Perceptron standar: [[69,3],[9,33]], akurasi=(69+33)/114=89,47%. Pada ADALINE standar η=0,01: [[69,3],[6,36]], akurasi=92,11%. Precision keduanya mirip, tetapi jumlah sampel M yang terlewat berbeda. Penamaan kelas sudah jelas dari diagnosis asli, sehingga FN dapat dijelaskan secara kontekstual.

8. Pembahasan dan Kesimpulan

8.1. Indikasi Linear dan Perbedaan Error

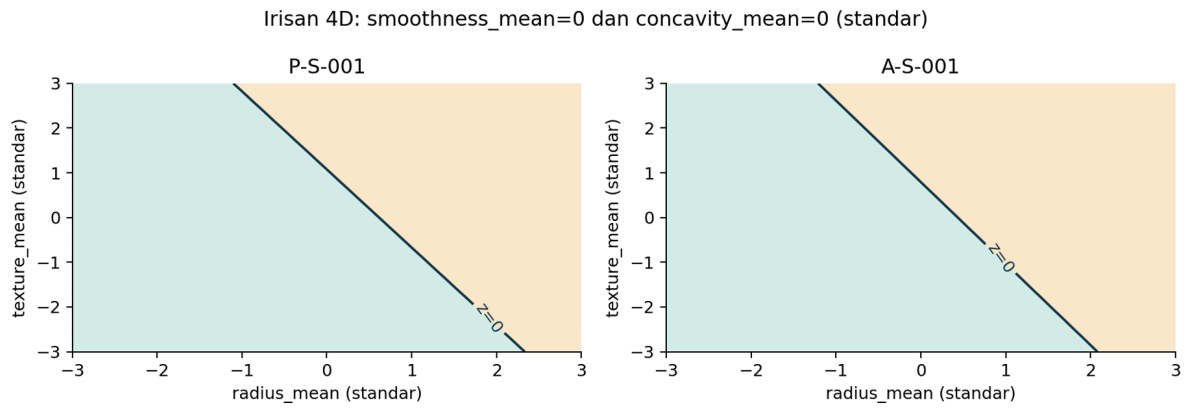
Perceptron standar masih melakukan 43 pembaruan pada epoch 50 dan menyisakan 36 kesalahan dari 455 data latih. Pola proyeksi dan akurasi latih menunjukkan struktur yang cukup cocok untuk keputusan linear, tetapi 50 epoch belum membuktikan separabilitas sempurna maupun ketidakmungkinannya. Irisan/proyeksi dua fitur tidak menentukan sifat ruang empat dimensi.

Perceptron memperbarui parameter dari error label diskret y-yhat. ADALINE memakai error kontinu y-z, termasuk sampel yang kelasnya sudah benar. Karena itu, akurasi yang sama tidak berarti bobot, margin, loss, atau proses pembelajaran sama. Jumlah update Perceptron tidak sebanding langsung dengan J ADALINE.

8.2. Learning Rate dan Standardisasi

Tiga eta Perceptron standar memberi riwayat update dan prediksi yang sama. Dengan w=b=0, urutan tetap, eta positif konstan, dan ambang nol, bobot serta bias proporsional terhadap eta sehingga tanda z tidak berubah. Hasil ini sah dan telah diperiksa, bukan bukti eta selalu tidak berpengaruh pada setiap implementasi.

Pada eta=0.01, Perceptron standar mencapai akurasi uji 89.47%, sedangkan raw 39.47%. ADALINE standar mencapai 92.11%, sedangkan raw 36.84% dengan J=6.659e+67. Skala asli radius/texture jauh lebih besar daripada smoothness/concavity, sehingga kontribusi langkah tidak seimbang. ADALINE raw mengalami divergensi loss, bukan sekadar konvergensi lambat.



Gambar 5. Irisan model 4D pada smoothness_mean dan concavity_mean standar=0. Garis z=0 memperlihatkan pengaruh radius/texture pada dua model fokus η=0,01. Titik proyeksi tidak dianggap sebagai titik pada irisan ini.

8.3. Keterbatasan dan Pengembangan

Satu split dengan 114 data uji membatasi generalisasi. Satu perubahan prediksi setara 0.88 poin persentase. Empat dari 30 fitur dipilih secara apriori, sehingga informasi lain tidak digunakan dan subset ini tidak diklaim optimal. Ketergantungan antarfitur dan asal satu benchmark membatasi transfer ke populasi lain. Tidak ada validasi eksternal atau kalibrasi probabilitas. Z bukan probabilitas.

Pengembangan dapat membandingkan semua fitur atau subset lain menggunakan validasi terstratifikasi di dalam train, kemudian memilih eta/epoch tanpa melihat test. Gunakan beberapa seed dan validasi eksternal. Data uji akhir harus tetap terpisah sampai seleksi selesai.

8.4. Kesimpulan

Implementasi NumPy kedua model, delapan pelatihan 50 epoch, serta pemeriksaan numerik telah selesai. Pada rancangan ini Perceptron standar menghasilkan akurasi uji 89.47% untuk tiga eta, sedangkan ADALINE standar menghasilkan 93.86%, 92.11%, dan 90.35%. Standardisasi menjaga ADALINE stabil pada eta yang diuji. Penurunan J tidak menjamin kenaikan akurasi kelas. Tidak dilakukan seleksi model berdasarkan data uji.

9. Daftar Pustaka

[1] UCI Machine Learning. Breast Cancer Wisconsin (Diagnostic) Data Set. Kaggle. https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data. Lisensi pada metadata Kaggle: CC BY-NC-SA 4.0.

[2] Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B. Lisensi sumber asli: CC BY 4.0.

[3] Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. IRE WESCON Convention Record, Part 4, 96-104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf. Artikel fundamental asli ADALINE.

[4] Raschka, S. (2015, 24 Maret). Single-Layer Neural Networks and Gradient Descent. https://sebastianraschka.com/Articles/2015_singlelayer_neurons.html. Tutorial dan kode pendukung.

[5] Raschka, S. (tanpa tahun). Adaline: Adaptive Linear Neuron Classifier. Dokumentasi mlxtend. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/.

[6] scikit-learn developers. StandardScaler; train_test_split. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html dan https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html. Versi eksekusi 1.8.0.

[7] Panduan internal mata kuliah (2026). Tugas Besar 1: Analisis dan Implementasi Klasifikasi Data Menggunakan Perceptron dan ADALINE. IT6053, FTI UKDW. Sumber ketentuan tugas yang diberikan pengguna.

10. Lampiran A. Dua Update Perceptron

Konfigurasi P-S-001, η=0,01

Urutan fitur: radius_mean, texture_mean, smoothness_mean, concavity_mean. Row_id dimulai dari 0 pada dataset.csv. Sampel posisi train 0 berlabel +1 dan diprediksi +1 saat z=0, sehingga tidak memperbarui parameter. Dua pembaruan pertama terjadi pada posisi 1 dan 2. Angka di bawah dibulatkan enam desimal, komputasi memakai presisi penuh.

Langkah 1: row_id=170, posisi train=1

x = (-0.516364, -1.639710, 0.476219, -0.604281)

w lama = (0.000000, 0.000000, 0.000000, 0.000000); b lama=0.000000

y = -1

z = $w^T x+b=0.000000000 \geq 0$, sehingga $\hat{y}=+1$

Δ = 0,01(-1-1)=-0,02

Komponen	w lama	Δx	w baru
w1	0.000000	0.010327	0.010327
w2	0.000000	0.032794	0.032794
w3	0.000000	-0.009524	-0.009524
w4	0.000000	0.012086	0.012086

b baru = 0.000000+(-0.020000)=-0.020000

Langkah 2: row_id=407, posisi train=2

x = (-0.368118, 0.455515, -1.432979, -0.342175)

w lama = (0.010327, 0.032794, -0.009524, 0.012086); b lama=-0.020000

y = -1

$z = w^T x + b = 0.000649431 \geq 0$, sehingga $\hat{y} = +1$

$\Delta = 0{,}01(-1-1) = -0{,}02$

Komponen	w lama	Δx	w baru
w1	0.010327	0.007362	0.017690
w2	0.032794	-0.009110	0.023684
w3	-0.009524	0.028660	0.019135
w4	0.012086	0.006844	0.018929

b baru=-0.020000+(-0.020000)=-0.040000

11. Lampiran B. Dua Batch ADALINE

Konfigurasi A-S-001, η=0,01, n=455

Batch memakai seluruh data train terstandardisasi, urutan fitur sama dengan Lampiran A. Error e=y-(Xw+b), J awal=0,5. Seluruh gradient satu batch dihitung dari parameter sebelum update.

Iterasi batch 1

w lama=(0.000000, 0.000000, 0.000000, 0.000000)

b lama=0.000000000

Fitur	$\Sigma x_i e_i$	$\Sigma x_i e_i / n$	w baru
radius_mean	320.555831	0.704518	0.007045
texture_mean	182.075685	0.400166	0.004002
smoothness_mean	171.065199	0.375967	0.003760
concavity_mean	300.978229	0.661491	0.006615

$w \text{ baru} = w \text{ lama} + 0{,}01(X^T e/455)$

mean(e)=-0.252747253

b baru=0.000000000 + 0,01(-0.252747253) = -0.002527473

J sesudah update=0.487138871

Iterasi batch 2

w lama = (0.007045, 0.004002, 0.003760, 0.006615)

b lama = -0.002527473

Fitur	$\Sigma x_i e_i$	$\Sigma x_i e_i / n$	w baru
radius_mean	314.397487	0.690983	0.013955
texture_mean	178.348982	0.391976	0.007921
smoothness_mean	167.144064	0.367350	0.007433
concavity_mean	294.343640	0.646909	0.013084

w baru = w lama+0,01($X^T e$/455)

mean(e) = -0.250219780

b baru = -0.002527473 + 0,01(-0.250219780) = -0.005029670

J sesudah update = 0.474793677